Das Kreuz mit dem Kreuzen

Leitfaden für schriftliche Prüfungen im Multiple-Choice-Format

Stand 01.06.2024

Kontakt:

Univ.-Prof. Dr. med. Sarah König, MME

Institut für Medizinische Lehre und Ausbildungsforschung

Josef-Schneider-Str. 2, Haus D6

97080 Würzburg

E-Mail: koenig_sarah@ukw.de

Telefon: +49 (0)931/201-55220

Sehr geehrte Prüfungsverantwortliche, Dozentinnen und Dozenten,

vielen Dank, dass Sie sich für die standardisierte Erstellung von (medizinischen) Prüfungsfragen interessieren!

Im der Medizin erfreuen sich Multiple Choice (MC)-Prüfungen nicht zuletzt wegen der fairen und ökonomisierten Durchführung einer großen Beliebtheit. Das zugrundeliegende Prinzip ist, dass die Studierenden bzw. Prüfungsteilnehmenden die korrekten Antworten aus einer vorgegebenen Liste an Antwortalternativen auswählen, sprich „kreuzen“. Eine relativ große Anzahl an Prüfungsaufgaben ist möglich und ergibt damit eine adäquate Stichprobe mit Blick auf das Gelernte der Studierenden. Weil die Prüfungsergebnisse digital erfasst und automatisiert ausgewertet werden können, sind sie gerade bei großen Studierendenzahlen ein wirksames Instrument, um den Korrekturaufwand zu reduzieren. Bei MC-Fragen muss besonders darauf geachtet werden, dass die Aufgaben korrekt konstruiert und verständlich formuliert sind – und dass sie eben nicht durch Raten oder Knobeln gelöst werden können.

In diesem Leitfaden finden Sie neben der Anleitung zum Erstellen von MC-Fragen bzw. ganzer Prüfungen Hinweise, Tipps und anschauliche Beispiele aus der Prüfungspraxis. Der Leitfaden beruht auf internationalen Standards zur Konzeption von MC-Prüfungen und enthält Beispiele aus der Würzburger Prüfungspraxis.

Um den Leitfaden kompakt zu gestalten, sind lern- und prüfungstheoretische Hintergründe sehr kurz gefasst.

Gerne stehen wir Ihnen beratend für Ihre MC-Prüfung — elektronisch unterstützt auf Papier oder rein digital mittels Tablets — zur Verfügung.

Viel Erfolg für die Aufgaben- und Prüfungserstellung wünschen Ihnen
Sarah König und das E-Prüfungsteam
(pruefungen.humanmedizin@uni-wuerzburg.de)

Würzburg, im Sommersemester 2024

Inhalt

1. Allgemeiner Aufbau von MC-Fragen 3
2. Beschreibung der einzelnen Fragenformate und deren Einsatz 4
2.1 MC-Frage: Typ A - Wahl einer bestmöglichen Antwort 5
2.1.1 Beispiel für Typ A_{pos} 5
2.1.2 Beispiel für Typ A_{neg} 5
2.1.3 Generelle Hinweise zum Typ A 6
2.2 Kprim – vierfache Entscheidung richtig/falsch 6
2.3 PickS - Wahl einer vorgegebenen Anzahl bester Antworten 8
2.4 Teilpunktevergabe bei Kprim und PickS 9
2.5 Klinische Fälle mit mehreren Fragen 10
2.5.1 Key-Feature-Fragen (KFQ) in Tablet-Prüfungen 10
2.5.2 Extended-Matching-Fragen (EMQ) in Tablet-Prüfungen 11
2.5.3 Sternförmige Fälle für Papierprüfungen 12
3. Ungewollte Lösungshinweise vermeiden 13
4. Eine MC-Prüfung zusammenstellen… 15
5. Anregungen zum Aufgaben-/Fragen-Review 16
6. Grundbegriffe der Teststatistik und quantitative Kenngrößen 16
5.1 Aufgabenschwierigkeit/Lösungshäufigkeit 16
5.2 Trennschärfe 17
5.3 Diskriminationsindex 17
5.4 Reliabilität 18
Verwendete und empfohlene Literatur 20

Das Kreuz mit dem Kreuzen
Schriftliche Prüfungen im MC-Format

1. Allgemeiner Aufbau von MC-Fragen

- **Prüfungsziel**: Studierende nennen die häufigsten Erreger einer bakteriellen Sekundärpneumonie bei Influenza-Infektion

Eine 70-jährige Frau im Altenheim erkrankt an einer Influenza-Grippe. Eine Woche später stirbt sie an einer sekundären, durch bakterielle Superinfektion bedingten Pneumonie.

Vignette

Welcher der folgenden Erreger ist am wahrscheinlichsten ursächlich für diese Pneumonie?

Frage

FRAGESTAMM

a) Mycobacterium tuberculosis
b) Listeria monocytogenes
c) Staphylococcus aureus
d) Chlamydia psittaci
e) Haemophilus parainfluenzae

- Wir sprechen in der Regel von Multiple Choice (MC)-Prüfungen. Im eigentlichen Sinne sollte die korrekte Bezeichnung „**Antwortauswahlverfahren**“ lauten, denn grundsätzlich kann sowohl die einfache (Single Choice) als auch mehrfache (Multiple Choice) Auswahl gemeint sein.

- Das **Prüfungsziel** steht am Anfang. Es stellt den Ausgangspunkt für eine gelungene Prüfungsaufgabe dar und erlaubt eine kohärente Konstruktion der MC-Frage

- Der **Fragestamm** kann in eine Fallvignette und die eigentliche Frage unterteilt werden. Die Vignette enthält alle für die Beantwortung der Frage notwendigen Informationen. In den Antwortoptionen sollten keine weiteren Informationen „versteckt“ sein.

- Die **zutreffenden (n) Antwort(en) und ihre Distraktoren** – Formulieren Sie zunächst die erwartete(n) Antwort(en) zum Fragenstamm. Dann erst sollten die Distraktoren (Ablenker) verfasst werden. Grundsätzlich gilt: Kurze, klare Antwortoptionen formulieren! Dabei ist zu beachten, dass die gewählten Antworten sowie formal (Textlänge und Grammatik) als auch inhaltlich homogen sein sollten (z. B. jeweils nur Untersuchungsmethoden, Differentialdiagnosen, Therapien) und sich in gleicher

Weise auf den geschilderten Fall bzw. das Prüfziel beziehen.

- Plausibel und gut formulierte **Distraktoren** stellen das Grundprinzip guter MC-Prüfungen dar, wenngleich sie das Problem des Erratens der Aufgabe nicht lösen können. Für die Distraktoren sollten klare Gründe bestehen (z. B. keine Passgenauigkeit zum Fall, Verwechslungen, veraltete Ansichten, Fehlmeinungen und Misskonzepte, welche bei den Studierenden häufig vorkommen). Sie enttarnen sich nicht selbst und stellen auch keine Absurditäten dar.

- Vermeiden Sie unbedingt versteckte Lösungshinweise (**Cues,** s. u.). Sie werden von den Studierenden „zielsicher aufgespürt“ und ermöglichen das Beantworten einer Frage, ohne über das eigentlich erforderliche Wissen zu verfügen.

- **Relevanz** – Das Thema der Frage sollte inhaltlich sowohl im Hinblick auf die weitere Ausbildung (folgende Semester bzw. weiteres Studium) als auch die spätere ärztliche Tätigkeit relevant sein. Dabei muss das Niveau dem aktuellen Ausbildungsstand der Zielgruppe angemessen sein (kein Facharztniveau, keine „Kolibris“, aber auch keine Trivialitäten abfragen).

- **Anwendungsorientierung** – Fragen Sie kein reines Faktenwissen ab. Die Studierenden sollen vielmehr Zusammenhänge verstehen und Wissen im Kontext anwenden können (dies ist z. B. über klinische Fallvignetten, Einbezug von Befunden und Abbildungen möglich).

2. Beschreibung der einzelnen Fragenformate und deren Einsatz

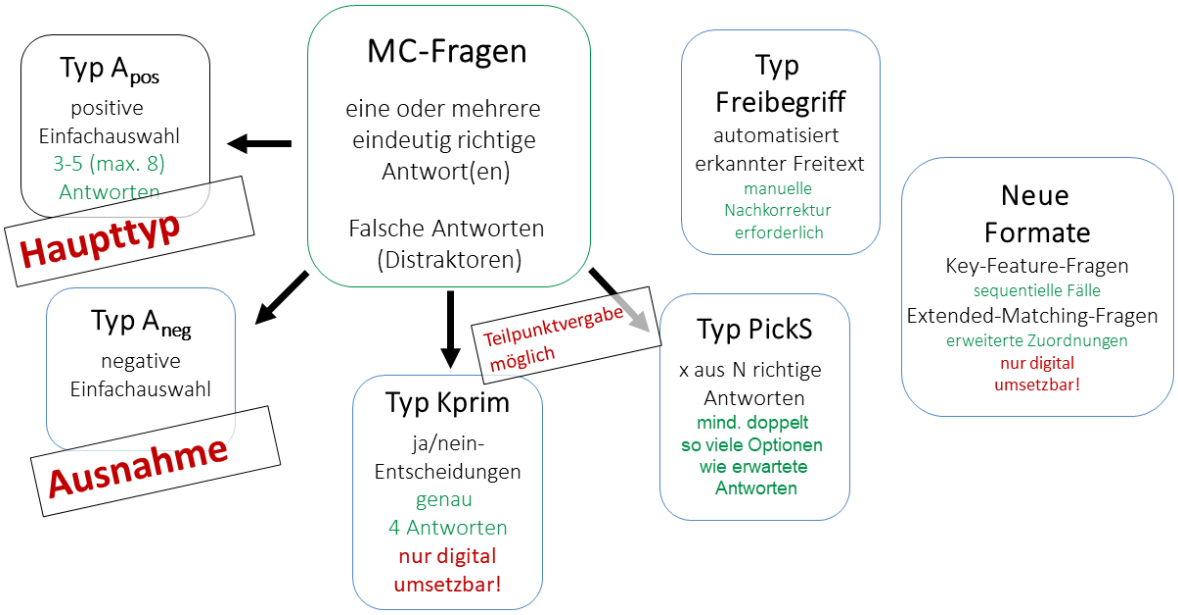

Abbildung 1 Übersicht über die verschiedenen Fragenformate

2.1 MC-Frage: Typ A - Wahl einer bestmöglichen Antwort

2.1.1 Beispiel für Typ A_{pos}

Eine 40-jährige Erstgravida in der 35. Schwangerschaftswoche wird mit heftigen Unterbauchschmerzen mit dem Rettungsdienst in den Kreißsaal transportiert.
Bei der letzten Routineuntersuchung bei der behandelnden Frauenärztin wurde erstmalig ein erhöhter Blutdruck (150/95 mmHg) sowie Knöchelödeme festgestellt. Die damalige Ultraschall-untersuchung zeigte einen Feten mit einem Schätzgewicht an der 5. Perzentile. Die Aa. uterinae zeigten bei der Doppler-untersuchung ein bilaterales Notching (frühdiastolische Inzisur).
Bei der jetzigen stationären Aufnahme äußert die Patientin starke Unterbauchschmerzen. Der Uterus ist „bretthart“ und druckdolent. Es besteht eine leichte vaginale Blutung. Das CTG ist hoch pathologisch.

Welche der folgenden Diagnosen trifft am wahrscheinlichsten zu?

a) vorzeitige Plazentalösung
b) Plazenta accreta
c) akutes HELLP-Syndrom
d) Plazenta praevia
e) Insertio velamentosa

2.1.2 Beispiel für Typ A_{neg}

In der Silvesternacht wird ein 20-jähriger Betrunkener vom Rettungsdienst in die Notaufnahme gebracht. Bei einer Kneipen-schlägerei habe er einen Schlag auf das rechte Auge bekommen. Der Patient gibt starke Schmerzen und eine Sehminderung an.

Welcher Folgezustand wird <u>am ehesten nicht</u> eintreten?

a) Arcus senilis
b) Berlin-Ödem
c) Hyphäma
d) Iridodialyse
e) Netzhaut-Foramen

2.1.3 Generelle Hinweise zum Typ A

Aufbau

Aus einer vorgegebenen Liste von Antwortoptionen müssen Prüflinge die bestmögliche Antwort auswählen. Üblicherweise werden **fünf Antwortoptionen** verwendet. Es kann jedoch aus inhaltlichen Gründen durchaus sinnvoll sein, lediglich 3 oder 4 Antwortoptionen vorzugeben, um das „Auffüllen“ mit offensichtlich falschen Distraktoren zu vermeiden.

Negativ formulierte Typ-A-Fragen sollten aus didaktischen Gründen den abzufragenden Wissensbereichen vorbehalten sein, in denen es um wichtige Ausnahmen oder Kontraindikationen geht. Alternativ kann eine vormalige Negativfrage in die Fragenformate **Kprim** oder **PickS umgewandelt** werden.

Wichtig: **Negationen** sollten bei der Typ A_{neg}-Frage grundsätzlich typographisch hervorgehoben werden. Doppelte Verneinungen sind unbedingt zu vermeiden.

Anwendungsbereich

Aus messtechnischen Gründen hat sich der Fragentyp A am besten bewährt und sollte eine Prüfung dominieren (mindestens 50% der Prüfungsfragen).
Das IMPP verwendet im M1/M2-Examen ausschließlich Einzelfragen vom Typ A, wobei der weit überwiegende Anteil sich auf Positivfragen erstreckt.

Hinweis: Fragenformate mit Antwortkombinationen sind obsolet, da sie häufig eher das Knobelvermögen der Prüflinge testen als deren Wissen.

2.2 Kprim – vierfache Entscheidung richtig/falsch

Welche(s) Symptom(e) ist/sind typisch für das frühkindliche Begleitschielen?

Bitte entscheiden Sie **bei jeder Aussage**, ob diese zutrifft oder nicht!

a) Doppelbildwahrnehmung
b) Schielbeginn im 1. Lebensjahr
c) Bestehen einer Myopie
d) Gleich großer Schielwinkel in alle Blickrichtungen

Aufbau

Prüflinge treffen für jede einzelne Antwort oder Aussage eine **Ja/Nein-Entscheidung** (z.B. richtig/falsch, adäquat/nicht adäquat, zutreffend/nicht zutreffend). Es sind deshalb nur Antworten tauglich, bei denen dies eindeutig möglich ist und die nicht

voneinander abhängen. Die Anzahl der **Antwortoptionen** ist in diesem speziellen Format **auf vier (4)** zu begrenzen!!! Selbst mit der Vergabe von Teilpunkten ist dieses Aufgabenformat im Sinne der Itemstatistik schwierig (niedrige Prüfungsleistung), d.h. Prüflinge verlieren relativ schnell Punkte, wenn Sie einen Fehler begehen, aber sonst doch korrekt wissen. Eine ausgelassene Entscheidung wird stets als falsche Antwort gewertet.
Die **Fragestellung** muss **neutral formuliert** werden und darf keinen Hinweis auf die Anzahl der erwarteten Antworten durch Formulierungen im Singular/Plural gegeben. Eine verneinende Fragestellung ruft im hohen Maße Irrtümer hervor und führt zur Anfechtbarkeit der Prüfungsaufgabe.

Bei diesem Aufgabenformat beachtet werden:

- In der Frage ist **offen zu lassen, wie viele der Aussagen zutreffen**. Daher muss sie so formuliert werden, dass sowohl die Einzahl als auch die Mehrzahl in Frage kommt. Gerne kann neutral formuliert werden (z.B. „Was trifft auf XY… zu?“).
- **Eine inhaltliche Aussage** steht immer alleine (nie zwei Aussagen in eine verpacken).
- **Vage Mengenbegriffe** wie „häufig“ oder „gewöhnlich“ sind zu **vermeiden**, da diese nicht eindeutig beurteilt werden können.
- Insgesamt sollte in der Konzeption einer Prüfung unter den Kprim-Fragen eine **ausgewogene Balance zwischen der Anzahl richtiger und falscher Antworten** bestehen. Prüflinge tippen bei Nicht-Wissen eher auf richtige/zutreffende Antworten, weshalb die Trennschärfe bei diesen Antworten schwächer ausfällt als bei falschen/unzutreffenden.
- Dieses Fragenformat eignet sich im Grundsatz nur für **rein digitale Prüfungen**. Das Nicht-Kreuzen auf einem Papierantwortbogen könnte im Falle einer falschen Antwortoption vom zufälligen Auslassen (sog. „Missing“) nicht unterschieden werden.
- Das Fragenformat sollte mit Bedacht (wünschenswert nur geringer Umfang) und auf keinen Fall dominierend in einer Klausur verwendet werden.

Anwendungsbereich
Kprim-Fragen eignen sich besonders, wenn mehrere Antworten gleich bedeutsam sind und/oder mehrere Antworten zu einer Lösung gehören. Dabei kann sowohl Faktenwissen als auch Anwendungswissen abgefragt werden.
Das Fragenformat eignet sich meist als „Ersatz“ für negativ formulierte Typ-A-Fragen.

2.3 PickS - Wahl einer vorgegebenen Anzahl bester Antworten

Herr Meyer (29 Jahre) stellt sich mit rechtsseitigen Unterbauchschmerzen dem chirurgischen Dienstarzt in der Notaufnahme vor.
Die Laborwerte zeigen eine eindeutige Entzündungskonstellation. Der Urin-Schnelltest ist unauffällig.

Welche Verdachtsdiagnosen kommen **am ehesten** in Frage?
3 Antworten treffen zu.

a) Divertikulitis
b) Pyelonephritis
c) Appendizitis
d) Reizdarm
e) Mesenterialischämie
f) M. Crohn

Aufbau
PickS-Fragen sind ähnlich aufgebaut wie Fragen vom Typ A. Es werden aber mehrere (mind. 2) zutreffende Antworten erwartet. Bei PickS-Fragen müssen die Prüflinge aus einer vorgegebenen Liste von Antwortoptionen (mindestens doppelt so viele Optionen wie zutreffende Antworten) die bestmöglichen erkennen. Die Anzahl der zutreffenden Antworten wird angegeben (im Unterschied zum Typ Kprim). Bei PickS ist speziell darauf zu achten, dass die einzelnen Antwortoptionen möglichst kurz und prägnant formuliert sind. Bei der Erstellung einer PickS-Frage sollte zuerst eine Antwortliste mit Themenbezug erstellt und erst dann der Fragenstamm (Fallvignette und Frage) entwickelt werden.

An der vorgenannten Beispielfrage ist nachzuvollziehen, dass Prüflinge einem Abwägungsprozess der besten Antworten unterliegen und daher die zutreffende Anzahl unbedingt vorgegeben werden muss. Ansonsten wäre im Beispiel auch eine weitere (vierte oder gar fünfte) Option der Differenzialdiagnosen vorstellbar, aber mit Bezug zur Fallvignette weniger wahrscheinlich.

Unter Umständen kann auch der Typ PickX ohne Vorgabe auszuwählender Antworten gewählt werden – in der Regel ist dem aber der Typ Kprim vorzuziehen.

Anwendungsbereich
PickS-Fragen eignen sich besonders für Problemstellungen, bei denen mehrere bestmögliche Antworten in Frage kommen (z. B. Erkennen der wahrscheinlichsten Diagnosen, Abwägen der sinnvollen diagnostischen Maßnahmen, Auswahl mehrerer Therapiemöglichkeiten). Dieses Fragenformat eignet sich außerdem für die Umwandlung von negativ formulierte Typ-A-Fragen.

2.4 Teilpunktevergabe bei Kprim und PickS

Grundsätzlich gilt bei der Auswertung, dass Prüflinge die volle Punktzahl erhalten, wenn alle Aussagen zutreffend ausgewählt bzw. bewertet wurden. Andernfalls (bereits bei einem Fehler bzw. einer Abweichung) wird die Frage mit 0 Punkten bewertet. Optional kann das Bewertungsschema mit Teilpunktevergabe abgemildert werden. Dies ermöglicht, insbesondere bei hohen Anforderungen, die Prüflinge in der Mitte der Skala des Leistungsniveaus besser zu differenzieren.

Prüfungsverantwortliche müssen das Bewertungsschema im Vorfeld für die gesamte Prüfung einheitlich festlegen. Wenn nichts explizit kommuniziert wurde, gilt das strengste Schema:

- **DS/AON** (Dichotomous scoring/Alles oder Nichts): volle Punktzahl nur, wenn alles zutreffend gelöst wurde

Folgende Bewertungsschemata mit Teilpunktevergabe können gewählt werden:

- **AHN** (Alles, Halbe oder Nichts): bei einer Abweichung wird die halbe Punktzahl vergeben
- **PS50P**: die Hälfte der Punktzahl wird vergeben, wenn mehr als die Hälfte der betreffenden Aufgabe gelöst wurde
- **PS 1/n**: anteilige Punkte für jede zutreffende Antwort (bei vier Antwortoptionen also je ¼ = 0,25 Punkte). Bitte beachten Sie, dass bei diesem Bewertungsschema krumme Punktewerte entstehen.

Je nachdem, wie viele Antwortoptionen zu einer Frage vorgegeben sind und wie viele Antworten als zutreffend erwartet werden, unterscheiden sich die Bewertungsschemata.

Technisch ist auch die Zuordnung von Bewertungsschemata zu einzelnen Aufgaben möglich – die Abweichung(en) sollte(n) aber wohlüberlegt und gut kommuniziert sein.

Für **falsche Antworten gibt es 0 Punkte**, es dürfen keine Punkte von der bereits gezeigten Leistung abgezogen werden („Maluspunkte“). Im Jahr 2008 urteilte das Oberverwaltungsgericht Münster, dass ein Bewertungsverfahren ungültig ist, wenn „für eine falsche Antwort Punkte abgezogen werden, die durch eine richtige Antwort erreicht worden sind“. Ein Prüfungsverfahren, das so gestaltet sei, könne keine „Aussagen darüber gewinnen, welche berufsbezogenen Kenntnisse der Prüfling hat“.

2.5 Klinische Fälle mit mehreren Fragen

2.5.1 Key-Feature-Fragen (KFQ) in Tablet-Prüfungen

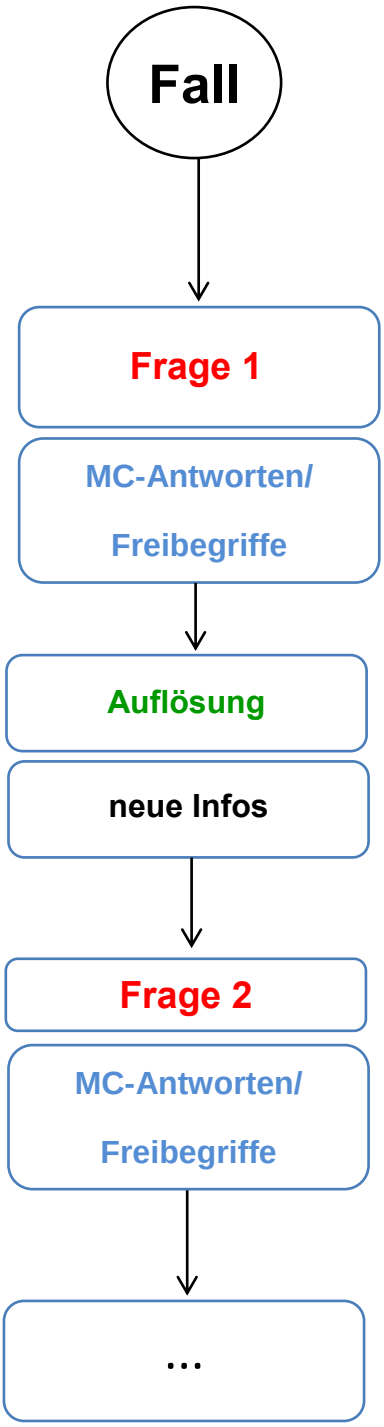

Ein 47-jähriger Mann (Herr Schreiber) stellt sich mit rezidivierenden Schmerzen in der rechten Leiste vor. Der Patient berichtet, dass sich der Schmerz während eines Tennisspiels vor ungefähr drei Monaten erstmals eingestellt und er anschließend zu Hause eine „wegdrückbare“ Schwellung bemerkt habe.

Frage 1: Welche ist die wahrscheinlichste Diagnose?

Zutreffende Antworten als Freibegriffe

- **Leistenhernie/-bruch**
- **Schenkelhernie/-bruch**

Anamnese und Beschwerdebild des Patienten deuten auf eine Leistenhernie hin.

Bei der digitalen Untersuchung der rechten Leiste ist unter „Hustenmanöver“ des Patienten eine ca. 2 × 2 cm große prall-elastische, nicht schmerzhafte Schwellung zu tasten.

Frage 2: Welche Therapieempfehlung ist dem Patienten bei neu aufgetretener Leistenhernie auszusprechen?

Zutreffende Antworten als Freibegriffe

Leistenhernienverschluss

- **Leistenhernien-OP**
- **Operative Behandlung eines Leistenbruchs**

Aufbau

Key-Feature-Fälle bestehen aus der Darstellung einer klinischen Situation gefolgt von 3 bis 5 oder mehr Aufgaben/Fragen. Weil die Fragen sequenziell aufeinander aufbauen und damit nachfolgend versteckte Lösungshinweise enthalten (abhängige

Konstruktion), darf ein Zurückblättern möglich sein, um gegebene Informationen erneut zu lesen. Die bereits eingetragenen Antworten dürfen vom Prüfling aber nicht mehr verändert werden. Somit ist hier die digitale Umsetzung der Prüfung auf Tablet zwingend erforderlich. Damit die Prüflinge nicht Folgefehlern unterliegen, wird jeweils zu Beginn der nächsten Frage die vorhergehende aufgelöst.
Als Fragenformate kommen hier grundsätzlich alle vorgestellten MC-Typen in Betracht. Zudem ist es möglich, die Prüflinge mit einem „Freibegriff“ antworten zu lassen. Hierfür muss eine „Positivliste“ zutreffender Antworten und Alternative bzw. verschiedene Schreibweisen (z. B. Ultraschall, Sonographie) hinterlegt werden. Die Auswertung erfolgt durch automatisierte Erkennung. Der Prüfungsverantwortliche muss allerdings die nicht erkannten Begriffe manuell nachkontrollieren. Da die Begriffe in eine Excel-Tabelle exportiert werden, ist dies mit relativ überschaubarem Aufwand verbunden.

Anwendungsbereich
Key-Feature-Fälle können prozedurales Wissen und damit die situationsbezogene Anwendung prüfen. Sie werden eingesetzt, wenn kritische Entscheidungen getroffen werden oder wenn eine Entscheidung an einer Weichenstellung zu fällen ist. Sie fokussieren auf Schwierigkeiten, die häufig in der Praxis anzutreffen sind und legen ihren Schwerpunkt auf das Erkennen von und den Umgang mit Problemen. Daneben können sie aber auch die häufigen Fehler von Studierenden bzw. Novizen im Berufsalltag adressieren.

Zur Entwicklung von Key-Feature-Fällen ist folgende Vorgehensweise empfehlenswert (Kopp 2006):

1. Definition eines Kontextes
2. Wahl der klinischen Situation
3. Identifikation der Key-Features des klinischen Problems
4. Schreiben des klinischen Szenarios (Fallvignette)
5. Schreiben der einzelnen Key-Feature-Fragen
6. Auswahl des jeweiligen Fragenformats
7. Inhaltsvalidierung durch zweifaches Review: erstens im Fachkollegium und zweitens interdisziplinär

2.5.2 Extended-Matching-Fragen (EMQ) in Tablet-Prüfungen

Aufbau
Bei diesem Format der erweiterten Zuordnung handelt es sich um MC-Fragen vom TypA_{pos}, die zu einem thematischen Set zusammengefasst sind. Es werden meist **5 kurze Fallszenarien** beschrieben, die jeweils am besten passende Antwort wird aus einer Liste mit in der Regel **8 homogenen Antwortoptionen** (z.B. Leitsymptom,

Immunerkrankungen, Diagnostikmaßnahmen, OP-Verfahren, Medikamente) ausgewählt bzw. zugeordnet. Dabei kann jede Antwort einmal, mehrfach oder überhaupt nicht verwendet werden.

Hier finden Sie ein Beispiel zum Thema „Bauchschmerzen“ mit einer Liste aus 8 möglichen abdominellen Erkrankungen, die zu 5 charakteristischen Fällen passen.

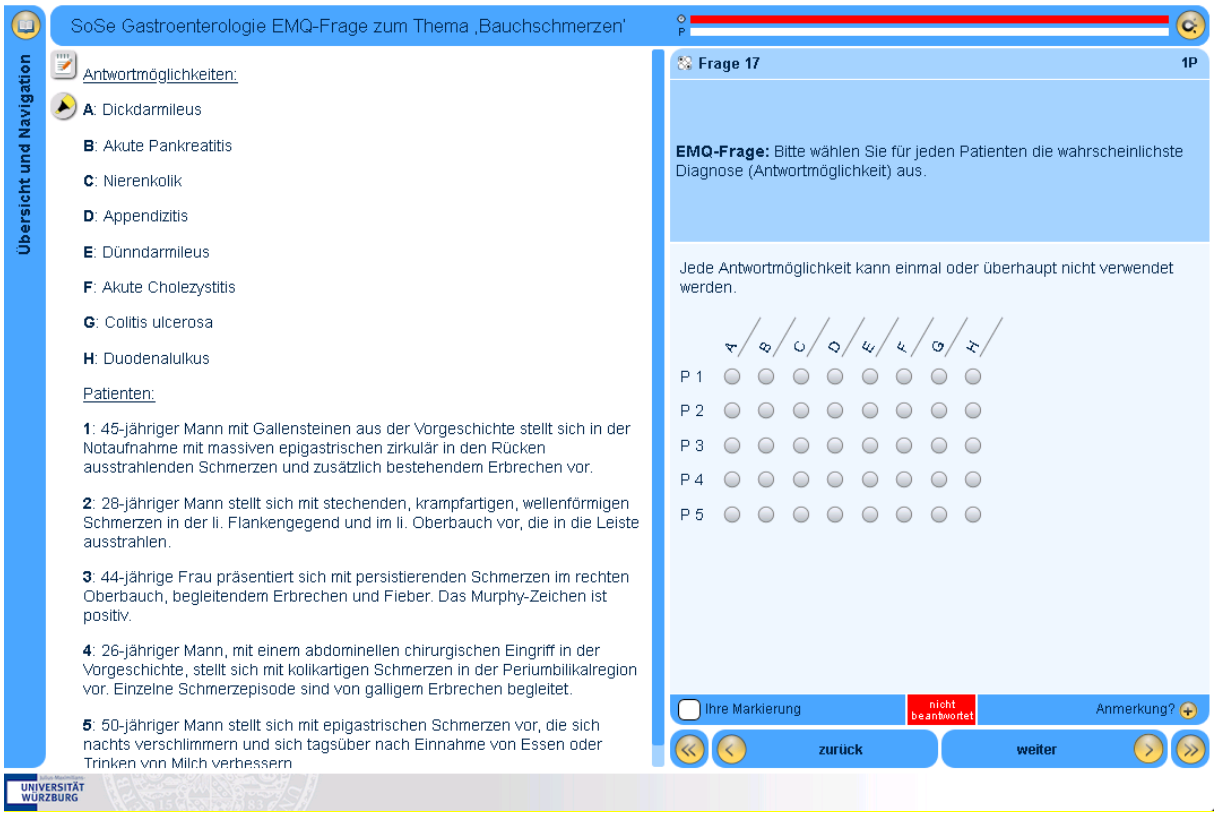

2.5.3 Sternförmige Fälle für Papierprüfungen

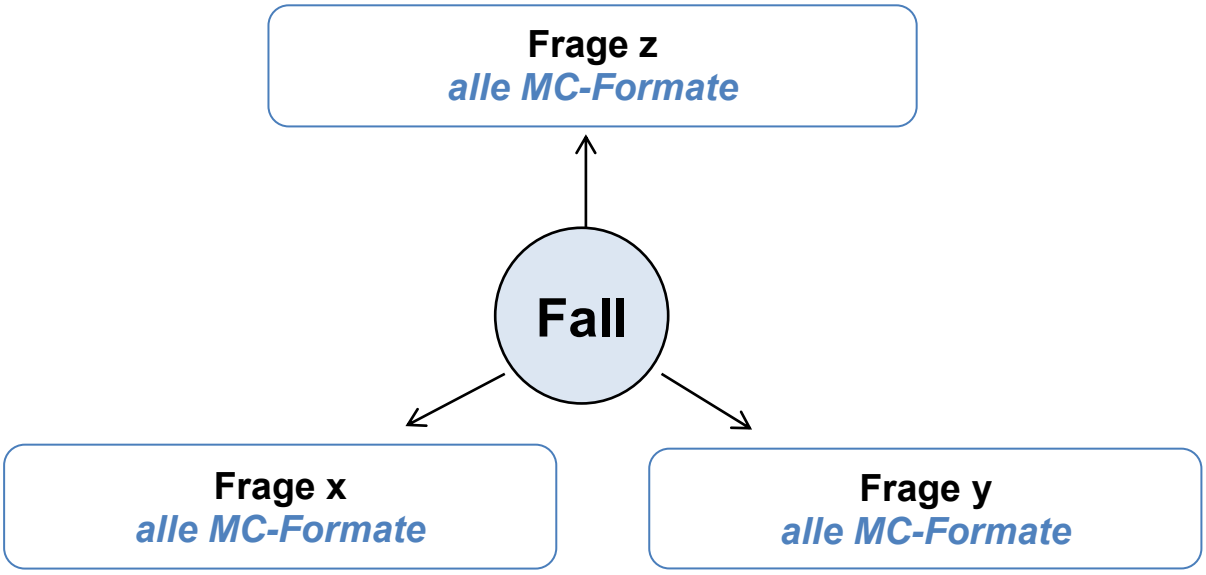

Aufbau
Bei papierbasierten Prüfungen können nur voneinander unabhängige Fragen zum Fall gestellt werden, weshalb hier eher die Bezeichnung „sternförmige Fälle“ zutrifft. Es kommen grundsätzlich alle vorgestellten MC-Formate in Frage, die im Papierformat sinnvoll umsetzbar sind. Beim IMPP hat diese Fallkonstruktion die vormaligen ausführlichen Fallstudien abgelöst.

3. Ungewollte Lösungshinweise vermeiden

Cues sind versteckte Lösungshinweise, derer sich der Fragensteller in der Regel nicht bewusst sind. Die Prüflinge haben dafür aber ein besonderes Gespür bzw. sind trainiert, diese zu erkennen.

- Alle Antworten müssen **grammatikalisch zum Stamm passen.**
- **Distraktoren** sollen möglichst **genauso lang und sprachlich differenziert** sein **wie die zutreffende Antwort.**

  Die folgende Beispielfrage gibt als zutreffende Antwort eine sehr lang ausformulierte Aussage inkl. Erläuterung vor. Als weiteres Problem ist anzumerken, dass bei dieser MC-Frage die Antworten inhaltlich sehr heterogen konstruiert sind und verschiedene Dimensionen zur Ätiologie, Physiologie und Therapie allgemein zum Mittelohr (aber ohne konkreten Krankheitsbezug) erfassen.

  Vermeidungsbeispiel für einen unerwünschten Längen-Cue und heterogene Antworten:
  Welche Aussage zum Mittelohr trifft zu?

  a) Die Tubenbelüftungsstörung bei Kindern ist fast immer auf eine Gaumenspalte zurückzuführen.
  b) Bei der klassischen Stapesplastik wird der Amboss entfernt.
  c) Bei der Tympanoplastik Typ I wird eine Prothese zwischen Hammer und Steigbügelkopf eingesetzt.
  d) Das Mittelohr dient in erster Linie der Anpassung der akustischen Impedanz vom äußeren Ohr zum Innenohr (Schalldruckerhöhung auf das ovale Fenster um das 22-fache).
  e) Bei der Tympanoplastik Typ III wird nur das Trommelfell rekonstruiert.

- **Absolute Begriffe** wie z. B. „nie“, „immer“, „alle“, „ausschließlich“, um Aussagen eindeutig falsch zu machen, sind zu **vermeiden**

- Werden **zwei gegensätzliche Antworten** formuliert, ist fast immer **eine der beiden richtig**. Durch einen solchen Hinweis erhöht sich die Ratewahrscheinlichkeit auf 50 %.

  Vermeidungsbeispiel für einen unerwünschten Gegenseitigkeits-Cue:
  Welcher Zugangsweg zur Blutkulturentnahme sollte im Rahmen der Sepsisdiagnostik am ehesten gewählt werden?

  a) der liegende zentralvenöse Katheter
  b) die frisch punktierte periphere Vene
  c) die liegende periphere Verweilkanüle
  d) die arterielle Kanüle mit kontinuierlichem Spülsystem
  e) der neu gelegte zentralvenöse Katheter

- **Gegenseitige Lösungshinweise** zwischen verschiedenen Aufgaben auf inhaltlicher Ebene vermeiden.

- **Verbale Assoziationen** innerhalb einer Aufgabe zwischen Frage und Antwort(en) vermeiden. Häufig kommt vor, dass sich ein Wortbestandteil der Frage in der zutreffenden Antwort wiederholt.

  Vermeidungsbeispiel für einen unerwünschten Wortstamm-Cue:
  Die rezidivierende laryngeale **Papillomatose** ist eine Erkrankung verursacht durch das…

  a) humane Immundefizienz-Virus (HIV)
  b) Epstein-Barr Virus (EBV)
  c) Varizella-Zoster Virus (VZV)
  d) humane Papilloma-Virus (HPV)
  e) Herpes simplex Virus Typ 1 (HSV 1)

- **Konvergenz-Cues** sind zu vermeiden: die Antwort, welche die größte Zahl von Elementen mit anderen Antworten gemeinsam hat, ist mit erhöhter Wahrscheinlichkeit die richtige/zutreffende (sog. Konvergenzstrategie).

- **Hinweise vermeiden, welche die Aufmerksamkeit auf 2 Antworten konzentrieren** (Unterscheidung in nur einem Merkmal)

  Vermeidungsbeispiel für einen Aufmerksamkeits-Cue:
  Welche Reihenfolge von Stabilisierungsarten entspricht einer zunehmenden Lagestabilität einer Teilprothese unter Kaubelastung?

  a) tangential - sagittal - transversal - trigonal – zirkulär
  b) sagittal - tangential - transversal - trigonal – zirkulär
  c) trigonal - tangential - sagittal - transversal – zirkulär
  d) zirkulär - trigonal - transversal - tangential – sagittal

4. Eine MC-Prüfung zusammenstellen…

- Die Fragen bilden die Inhalte bzw. unterrichteten Lernziele der Lehrveranstaltung bzw. eines Teilbereichs repräsentativ ab (z. B. anhand eines **Blueprint** d. h. eines vorab ausgearbeiteten und gewichteten Verzeichnisses des Prüfungsstoffes).

- Für eine ausreichend hohe Reliabilität sollten **mindestens 40 Fragen** gestellt werden.

- Aus messtechnischen Gründen dominiert der **Fragentyp A (> 50 %)**, ein Anteil an **Kprim** von **nicht mehr als 20 %** ist empfehlenswert.

- Die Prüflinge sollen **Wissen verstehen und anwenden** (z. B. über klinische Fallvignetten, Einbezug von Befunden, Tabellen, Abbildungen etc.).

- Das **Prüfungssystem permutiert** die Fragenabfolge und Verteilung der Antworten.

- **Alte Fragen** sind mit großer Vorsicht wiederzuverwenden bzw. müssen unbedingt abgewandelt werden. Die meisten Fächer veröffentlichen ihre Aufgaben/Fragen freiwillig, um eine Vorbereitung auf die Prüfung zu ermöglichen. An dieser Stelle sei angemerkt, dass Altfragen nicht verheimlicht werden können, durch unerlaubte Strategien und unter Verletzung des Urheberrechtes entwendet werden. Daher ist die Aussage über das Leistungsniveau der Studierenden im Falle der Verwendung von Altfragen sehr eingeschränkt.

- Die Kalkulation der **Prüfungszeit** sollte sich nach der Anzahl der MC-Fragen und der verwendeten Formate richten. Besteht eine Prüfung aus überwiegend TypA-Fragen (ca. 80 %), dann stehen für die Bearbeitung jeder Aufgabe durchschnittlich 1,5 Minuten pro Frage zu Verfügung. Bei einem höheren Anteil von **Kprim** und **PickS** sollte die **Prüfungszeit verlängert** werden.

- Die gesamten Fragen einer Prüfung sollten im Zusammenhang durch mindestens **zwei weitere Personen prüfend gelesen** und ggf. korrigiert werden:
  1. Ein Inhaltsexperte sollte die fachliche Richtigkeit und Übereinstimmung mit der Lehre (Unterrichtsinhalten/Lernzielen) sicherstellen.
  2. Ein MC-Prüfungsexperte sollte Form und Sprache begutachten.
- Für die Übertragung der Aufgaben in **CaseTrain** (König et al. 2019) steht ein Online-Formular zur Verfügung: https://casetrain.uni-wuerzburg.de/eatform/

5. Anregungen zum Aufgaben-/Fragen-Review

Formal

- Aufgaben-/Fragenformat indiziert und passend zur Fragestellung (z.B. bei Typ A findet sich Abwägungspotenzial mit homogenen Antwortoptionen, bei Kprim Einzelentscheidungen)
- Antworten knapp formuliert, die Informationen befinden sich in der Vignette
- kein reines Erinnerungswissen, Anwendungsbezug gegeben (z. B. Problem-/Fallbeschreibung, Abbildungen, Diagramme)
- keine versteckten Lösungshinweise

Inhaltlich

- Vignette ist für Bearbeitung/Lösung unbedingt notwendig
- Fragestellung macht Vignette durch Schlagwort nicht überflüssig
- angegebene/n Lösung/en korrekt und eindeutig
- Distraktoren inhaltlich passend und nicht total abwegig
- angemessene Schwierigkeit für Ausbildungsniveau

6. Grundbegriffe der Teststatistik und quantitative Kenngrößen

Zusammen mit der Prüfungsauswertung erhalten Sie eine Auswertung der Gesamtprüfung sowie die statischen Kenngrößen zu jeder einzelnen Frage. Anhand der Teststatistik lassen sich auffällige Fragen (z. B. zu schwierig, geringe Trennschärfe) identifizieren. In einer zu empfehlenden Nachbesprechung mit Vertreterinnen und Vertretern der Prüfungsteilnehmenden kann daher die Auswertung eine geeignete Grundlage bieten, Probleme bzw. Fehler zu identifizieren.
Es gilt zu beachten, dass die Prüfungsauswertung inkl. der Berechnung der Bestehensgrenzen durchaus unterschiedlich ausfällt. Dies ist abhängig davon, ob nur die Erstteilnehmenden der Prüfung betrachtet werden oder die gesamte Prüflingskohorte inkl. der Nachschreiber einberechnet wird.

Im Folgenden finden Sie eine kurze Erklärung der wichtigsten teststatistischen Begriffe (Möltner et al. 2006).

5.1 Aufgabenschwierigkeit/Lösungshäufigkeit

Wie schwer ist die MC-Frage?
Wie viele Punkte wurden von den Kandidaten durchschnittlich erreicht?

Die Aufgabenschwierigkeit beschreibt die mittlere bei einer Aufgabe erreichte Punktzahl bzw. die mittlere relative erreichte Punktzahl bezogen auf die maximal erreichbare Punktzahl. Bei einer Aufgabenschwierigkeit von beispielsweise 0,81 (sofern die betreffende MC-Frage auch mit der Punktzahl 1 gewertet wird) haben also 81 % aller Prüflinge die Frage korrekt beantwortet.
Hohe Werte (in Richtung 1) kennzeichnen sehr leichte Aufgaben — sie wurden von

vielen bzw. fast allen Prüflingen gelöst. Niedrige Werte (in Richtung 0) kennzeichnen sehr schwere Aufgaben. Das führt häufig zu Verwirrung, weshalb auch bei den Werten von der Lösungshäufigkeit gesprochen werden könnte.

Die Gesamtschwierigkeit/-lösungshäufigkeit der Klausur entspricht dem Mittelwert aller Aufgabenschwierigkeiten/Lösungshäufigkeiten.

Richtwerte:
Als Richtwert für die Aufgabenschwierigkeit/Lösungshäufigkeit wird in der Literatur der Bereich zwischen *0,4 und 0,85* empfohlen.

- Schwere Aufgaben demotivieren und prüfen häufig Spezialwissen ab.
- Zu leichte oder zu schwere Aufgaben sind zur Differenzierung ungeeignet.

5.2 Trennschärfe

Kann man mit der Aufgabe „gute“ und „schlechte“ Prüflinge unterscheiden?

Die Trennschärfe beschreibt die „Fähigkeit" einer Aufgabe, zwischen guten und schlechten Prüflingen (im Sinne der in der Prüfung erreichten Gesamtpunktzahl) zu unterscheiden. „Erreichen Kandidaten mit einer hohen Punktzahl in der gesamten Prüfung bei einer Aufgabe relativ viele Punkte, Kandidaten mit niedriger Gesamtpunktzahl nur wenige, so besitzt sie eine hohe Trennschärfe“ (Möltner et al. 2006).

Richtwerte:
Trennschärfen von *über 0,3* gelten als gut, von 0,2 bis 0,3 als akzeptabel. Trennschärfen unter 0,2 sind marginal und unterscheiden minimal bis gar nicht zwischen guten und schlechten Prüflingen. Bei Aufgaben mit negativen Trennschärfen schneiden paradoxerweise die schlechten Prüflinge besser ab.

Ist eine Aufgabe zu leicht oder auch zu schwer, ergibt sich automatisch eine schlechtere Trennschärfe.

Es mag den **Sonderfall** geben, dass alle Prüflinge eine Aufgabe korrekt erfüllen und dies auch so vom Prüfungsverantwortlichen angelegt war („Das müssen alle gelernt/gewusst haben!“). In diesem Fall ergäbe die Aufgabenschwierigkeit/Lösungshäufigkeit 100 % bei einer Trennschärfe von 0.

5.3 Diskriminationsindex

Eine alternative Maßzahl für die Trennschärfe ist der Diskriminationsindex. Er gibt an, wie gut eine Aufgabe zur Leistungsdifferenzierung der Studierenden beiträgt. Dieser gibt die Differenz zwischen den Werten der Aufgabenschwierigkeit/Lösungshäufigkeit für Prüflinge mit hoher und niedriger Leistungsfähigkeit basierend auf z.B. Terzilen (oberes vs. unteres Drittel bzgl. der Gesamtpunktzahl) wieder. In anderen Worten, die Aufgabenschwierigkeit/Lösungshäufigkeit wird für beide Gruppen bestimmt und

daraus die Differenz gebildet. Im Gegensatz zur Trennschärfe gibt der Diskriminationsindex jedoch nicht die Schärfe der Trennung an, sondern die Stärke.

Der Diskriminationsindex kombiniert Aufgabenschwierigkeit/Lösungshäufigkeit und Trennschärfe und kann als Kennzahl einen Hinweis auf die Notwendigkeit der Überarbeitung von Aufgaben geben. So gibt Backhoff et al. (2000) folgende Empfehlungen:

D =	*Qualität*	*Empfehlung zur Überarbeitung*
> 0.39	exzellent	beibehalten
0.30 - 0.39	gut	Möglichkeit zur Verbesserung
0.20 - 0.29	mittel	Überarbeitungs-/Begutachtungsbedarf
0.00 - 0.20	schlecht	verwerfen oder vertieft begutachten
< -0.01	ungünstig	Definitiv verwerfen

In der ausführlichen Auswertung zeichnet sich damit folgendes anschauliche Bild:

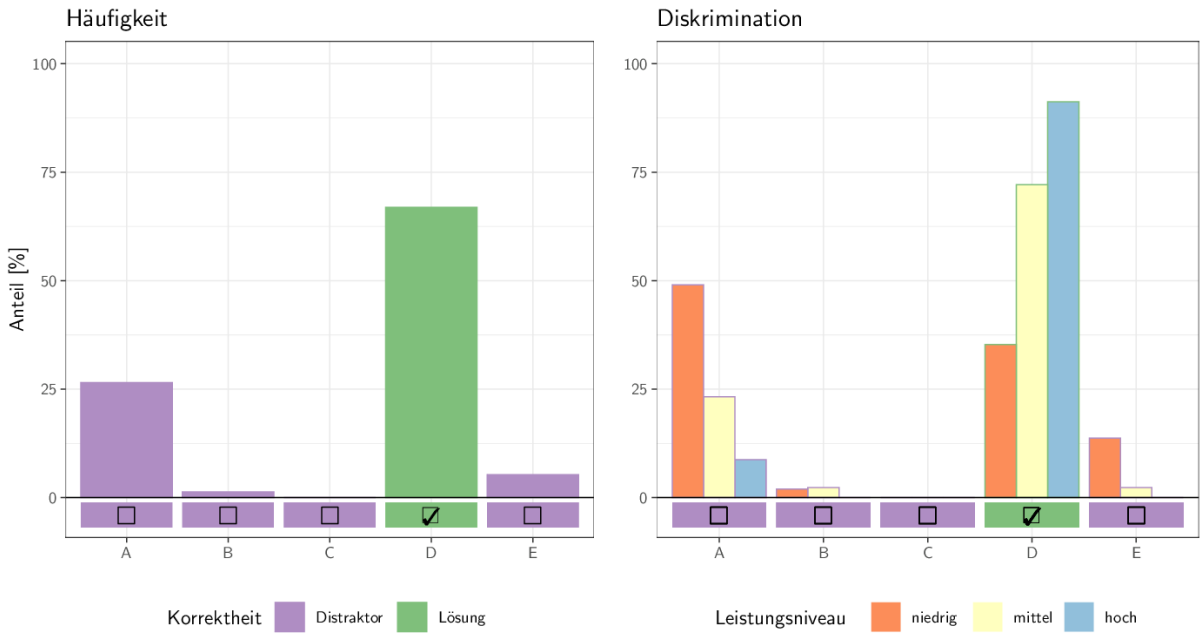

Abbildung 2 Hohe Diskriminationsfähigkeit (D = 0,49) bei guter Trennschärfe (0,49) und Aufgabenschwierigkeit/Lösungshäufigkeit (0,67). Farbige Balken markieren die Häufigkeit (bzw. die Schwierigkeit) für alle Prüflinge (links) bzw. für verschiedene Leistungsniveaus (rechts).

5.4 Reliabilität

Die Reliabilität (berechnet über Cronbachs Alpha) beschreibt die Zuverlässigkeit oder Reproduzierbarkeit von Prüfungsergebnissen. In der Literatur wird für Prüfungen eine Mindestreliabilität von 0,8 empfohlen.

Es gibt verschiedene Möglichkeiten, die Reliabilität zu steigern:

1. Verbesserung der Aufgabenqualität (hohe Trennschärfen, angemessene

Aufgabenschwierigkeit/Lösungshäufigkeit, keine ungewollten Lösungshinweise)

2. Erhöhung der Aufgabenanzahl (um eine Reliabilität von 0,8 zu erreichen, empfehlen sich mindestens 40 Fragen pro Prüfung)

Bei der aktuellen Prüfungsauswertung und seit 2022 wird dieser Wert nun standardmäßig und korrekt ausgegeben.

Verwendete und empfohlene Literatur

Backhoff, E, Larrazolo, N, Rosas, M. The Level of Difficulty and Discrimination Power of the Basic Knowledge and Skills Examination (EXHCOBA). Revista Electrónica de Investigación Educativa 2000; 2(1): 16.

Case S M, Swanson D B. Constructing Written Test Questions for the Basic and Clinical Sciences. National Board of Medical Examiners; 2003.

Fabry G. Medizindidaktik. Ein Handbuch für die Praxis (Kapitel 5 - Prüfungen: Information und Ergebniskontrolle, pp. 183-226). Bern: Huber; 2009.

König, S, Hörnlein A. "Prüfungen im Medizinstudium – mehr als nur Noten." Wiener Medizinische Wochenschrift 2019; 169(5-6): 126-131.

Krebs R. Anleitung zur Herstellung von MC-Fragen und MC-Prüfungen für die ärztliche Ausbildung. Institut für Medizinische Lehre IML, Universität Bern; 2004.

Kropf R, Krebs R, Rogausch A, Beyeler C. Auswirkungen angeleiteter Itemanalysebesprechungen mit Dozierenden auf die Qualität von Multiple Choice Prüfungen. GMS Z Med Ausbild. 2010; 27(3).

Möltner A, Schellberg D, Jünger J. Grundlegende quantitative Analysen medizinischer Prüfungen. GMS Z Med Ausbild. 2006; 23(3).

Rodriguez MC. Three Options are Optimal for Multiple-Choice Items: A Meta-Analysis of 80 Years of Research. Educational Measurement: Issues and Practice 2005; 24(2), 3-13.

Rotthoff T, Soboll S. Qualitätsverbesserung von MC Fragen: Ein exemplarischer Weg für eine Fakultät. GMS Z Med Ausbild. 2006; 23(3).

Schuwirth L W T, van der Vleuten C P M. ABC of Learning and Teaching in Medicine. Written Assessment. 2003; BMJ 326: pp. 643-645.

Smolle J. Klinische MC- Fragen rasch und einfach erstellen – ein Praxisleitfaden für Lehrende. Walter de Gruyter: Berlin, New York; 2008.

Text und Entwurf in Anlehnung an Peter Brüstle, *Kurzanleitung Prüfen mit MC-Fragen,* Studiendekanat Freiburg 2011.